

# Recap



ITAM

Clase 8 Curso Propedéutico  
2017/06/21

# Recap SVD

$$A = U \Sigma V^T$$

$U$  ortogonal  
 $V$  ortogonal  
 $\Sigma$  diagonal acompañada con ceros en dimensiones sobrantes



$$\begin{aligned}
 AV &= A [v^1 | v^2 | v^3] = [u^1 | u^2] \begin{bmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \end{bmatrix} \\
 &= [\sigma_1 u^1 | \sigma_2 u^2 | 0]
 \end{aligned}$$

# Solución de sistemas de ecuaciones con la SVD

$$(AB)^{-1} = B^{-1}A^{-1}$$

$$(AB)(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = AA^{-1} = I$$

- Supongamos que queremos resolver un sistema de ecuaciones

Si  $A = U\Sigma V^T$  entonces  $Ax = b$

$\tilde{A}^{-1}Ax = \tilde{A}^{-1}b$   $\tilde{A}^{-1} = V\tilde{\Sigma}^{-1}U^T$

$\tilde{A}^{-1}A = V\tilde{\Sigma}^{-1}U^T U \Sigma V^T = V\tilde{\Sigma}^{-1}\Sigma V^T = V\tilde{\Sigma}^{-1}\Sigma V^T = VV^T = I$  solución al sistema de ecuaciones si  $\sigma_j = 0$  poner 0

Es solución.  $x = V\tilde{\Sigma}^{-1}U^T b$

$\tilde{\Sigma}^{-1}\Sigma = I$  suprimiendo variable

Truco Invertir  $\Sigma = \begin{bmatrix} \sigma_1 & & 0 & | & 0 \\ & \ddots & & & \\ 0 & & \sigma_m & | & 0 \end{bmatrix}$   $\tilde{\Sigma}^{-1} = \begin{bmatrix} 1/\sigma_1 & & 0 & \\ & \ddots & & \\ 0 & & 1/\sigma_m & \\ \hline 0 & & 0 & \ddots & 0 \end{bmatrix}$

OJO: si  $A$  es invertible  $\tilde{\Sigma}^{-1}$  es la inversa de  $\Sigma$

**Nota!!!!** Observemos que este método siempre da una solución incluso si la matriz no es invertible!!!!!!

$$\tilde{\Sigma}\tilde{\Sigma}^{-1} = \begin{bmatrix} 1 & & 0 \\ & \ddots & \\ 0 & & 1 & & 0 \\ & & & \ddots & \\ 0 & & 0 & & 0 \end{bmatrix}$$

# Este método de solución de ecuaciones tiene muchas ventajas

- Estabilidad numérica ✓
- Menos sensibilidad a errores de redondeo ✓

# Algunos conceptos de cálculo numérico

<http://ta.twi.tudelft.nl/users/vuik/wi211/disasters.html>



# Número de condición

- Los errores numéricos surgen por errores de redondeo. La computadora solo puede representar un número con una cantidad finita de elementos (bits).
- El número de condición mide cuánto cambia la solución de un sistema de ecuaciones si el vector independiente tiene un error de redondeo  $e$

$$\kappa(A) = \frac{\sigma_{\max}}{\sigma_{\min}}$$

tenemos  $b$  y  $\hat{b} = b + \epsilon$

Comparamos las soluciones de  $Ax_1 = b$  y  $Ax_2 = \hat{b}$

$$x_1 - x_2 = \bar{A}^{-1}b - \bar{A}^{-1}\hat{b} = \bar{A}^{-1}\epsilon \quad \text{error en la solución}$$

Pregunta ¿qué tanta puede ser el cambio en la solución relativo al tamaño del error  $\epsilon$ ?


$$K(A) = \max_{b, \epsilon \neq 0} \left\{ \frac{\frac{\|\bar{A}^{-1}\epsilon\|}{\|\bar{A}^{-1}b\|}}{\frac{\|\epsilon\|}{\|b\|}} \right\} \quad \begin{array}{l} \text{tamaño} \\ \text{error relativo} \\ \text{a input } b \end{array}$$

error en solución relativo a tamaño solución

$$= \max_{\epsilon} \left( \frac{\|\bar{A}^{-1}\epsilon\|}{\|\epsilon\|} \right) \max_b \left( \frac{\|b\|}{\|\bar{A}^{-1}b\|} \right)$$

$$= \max_{\epsilon} \left( \frac{\|\bar{A}^{-1}\epsilon\|}{\|\epsilon\|} \right) \max_u \left( \frac{\|Au\|}{\|u\|} \right) = \frac{\|\bar{A}^{-1}\| \|A\|}{\sigma_{\min} \sigma_{\max}}$$

# Proyecciones on subespacios



$$\text{Proj}_V y = \beta_1 X^1 + \dots + \beta_n X^n = X\beta$$

Problema de Proyección

$$\min_{\beta} \|y - X\beta\| \sim \min_{\beta} \frac{1}{2} \|y - X\beta\|^2 \sim \min_{\beta} \underbrace{\frac{1}{2} (y - X\beta)^T (y - X\beta)}_{f(\beta)}$$

Derivamos e igualamos a cero

$$\begin{aligned} \nabla f(\beta) &= \frac{1}{2} \nabla (y^T y + \beta^T X^T X \beta - 2\beta^T X^T y) \\ &= \frac{1}{2} (2X^T X \beta - 2X^T y) \end{aligned}$$

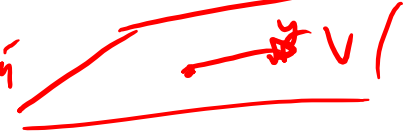
$$\nabla f(\beta^*) = 0 \iff \beta^* = (X^T X)^{-1} X^T y$$

$$\therefore \text{Proj}_V y = X\beta^* = X(X^T X)^{-1} X^T y = \hat{\Pi} y$$



Definición abstracta

$P$  se llama matriz de proyección en un espacio  $V$  si  $Pb = b \quad \forall b \in V$

• Pueden decir que  $\underline{X(X^T X)^{-1} X^T = \hat{H}}$  es la proyección 

en  $\text{span}(X^1, \dots, X^n)$ .

## Recap de todo el curso

Regresamos a SVD

dado  $A = U \Sigma V^T$

$\Sigma^+ = \tilde{\Sigma}^{-1}$  notación.

la pseudo inversa de  $A$  es la matriz

$$A^+ = X^{-1} = U \tilde{\Sigma}^{-1} V^T = U \Sigma^+ U^T$$

Si queremos resolver  $Ax = b \Rightarrow x = A^{-1}b$  si  $A$  es invertible  
pero si no es invertible  $x = A^+ b$  es la "mejor aproximación a una inversa".

Tarea: 1) Checar que  $A^+$  proyecta en  $\text{span}(A^1 \dots A^b)$  2) Investigar relación entre  $A^+$  y  $\hat{H}$

# ¿Qué hemos visto?

1. Vectores y proyecciones
2. Matrices/Transformaciones Lineales
3. Kernel e imagen (espacio columna) de una transformación/relación con sistemas de ecuaciones.
4. Determinante como distorsión del volumen.
5. Matrices inversas y relación con el determinante
6. Matrices Ortogonales
7. Eigenvectores
8. Optimización con y sin restricciones
9. Funciones cuadráticas
10. Descenso gradiente
11. Descomposición SVD
12. Relación entre SVD, optimización y normas matriciales
13. SVD, Eigenvectores y Optimización.

- 1 Vector = dirección + magnitud / flecha / lista ordenada,  $v \in \mathbb{R}^n$
- 2 matriz = "arrays" o "listas de listas" / transformaciones: sus columnas son el efecto sobre vectores canónicos  
 /  $A \in \mathbb{R}^{m \times n}$   $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$   $T(x) = Ax$

- 3 Kernel e imagen:
- subespacios
  - $\text{Ker}(A) = \{v \mid Av = 0\}$
  - $\text{Im}(A) = \{w \mid \text{existe } v \text{ tal que } Av = w\}$
- 

•  $\frac{\dim(\text{Ker})}{\text{nulidad}} + \frac{\dim(\text{Im})}{\text{rango}} = n$

Dado un sistema de eq. l.m.  $Ax = b$

- tiene solución  $\Leftrightarrow b \in \text{Im}(A) \Leftrightarrow \exists x: b = \sum x_i A^i$
- si hay una solución dice cuántas hay


$\hookrightarrow$  si  $\text{Ker}(A) = \{0\}$  solo hay una



$\xrightarrow{A}$




- 4 Determinante: mide distorsión en volumen  $\det(A) = \frac{\text{Vol}(A(E))}{\text{Vol}(E)}$



- Para matrices cuadradas
- $\det(A) = \prod \lambda_i$  producto de los eigenvalores de A
- A invertible  $\Leftrightarrow \det(A) \neq 0$

5

- 6) Ortogonales: transpuesta e inversa son la misma  
 $A^T A = I$   $(A^i, A^j) = \begin{cases} 1 & \text{si } i=j \\ 0 & \text{si } i \neq j \end{cases}$   
 • Como transformaciones son rotaciones y reflexiones  
 •  $\det(A) = \pm 1$

- 7) Eigenvalores y diagonalización:
- $Av = \lambda v$   $\leftarrow$   $\begin{matrix} \text{eigen} \\ \text{vector} \end{matrix}$   
 $\uparrow$   
 $\text{de eigenvalor}$
- 

Diagonalización


- A es diagonalizable si existe W ortogonal y D diagonal  
 tal que  $A = W D W^{-1}$   
 $(A W = W D)$

$$W = [w^1 | \dots | w^n]$$

$$D = \begin{bmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{bmatrix}$$

multiplicar por  $W^{-1}$  es  
 cambiar a coordenadas  $[w^1 | \dots | w^n]$

- Diagonalizar equivale a encontrar base de eigenvectores




- Caso  $A$  simétrica

- siempre es diagonalizable

- la base de eigenvectores es ortonormal

$A = W D W^T =$  rotar/reflexar  $\rightarrow$  reescalar  $\rightarrow$  desrotar/desreflexar



Leción :  $\wedge$  Todas las matrices equivalentes a una matriz diagonal salvo rotaciones

8,9,1) Repaso pero nos ayudó a entender normas entre otras cosas

16) Descenso gradiente:

- El método favorito de optimización en big data

- $\nabla f$  apunta al máximo ascenso
- $-\nabla f$  al máximo descenso
- Movimientos  $x_k = x_{k-1} - \alpha \nabla f(x_{k-1})$
- Llegamos a un mínimo

Final) SVD :

$$A = U \Sigma V^T$$

- El resultado más padre de álgebra
- Dice como aproximar matrices reduciendo complejidad
- Matrices de cualquier tamaño
- Se construye definiendo el efecto de  $A$  en una esfera
- Describe  $A$  como rotación  $\rightarrow$  rescalamiento  $\rightarrow$  otra rotación
- $\sigma_1 = \|A\| = \max \frac{\|Ax\|}{\|x\|}$
- $\sigma_1, \sigma_2, \dots$  son los tamaños de ejes del elipsoide imagen de la esfera por  $A$
- siempre existe
- permite solucionar sistemas de ecuaciones establemente
- define una pseudoinversa
- etc
- $U$  son los eigenvec de  $AA^T$  y  $V$  de  $A^TA$