

# Probabilidad

ITAM

Clase 13 Curso Propedéutico  
2017/07/04

# Propiedades de Esperanza y Varianza

Esperanza  $E(X) =$  "Promedio ponderado de posibles valores de  $X$ "

$$= \left\{ \begin{array}{l} \sum_x x P(X=x) \\ \int_{\mathbb{R}} x f_X(x) dx \end{array} \right\} = \int_{\mathbb{R}} x dF_X(x)$$

Propiedades:  $X, Y$  v.a  $a \in \mathbb{R}$

$$\textcircled{1} \quad \begin{array}{l} E(X+Y) = E(X) + E(Y) \\ E[aX] = a E(X) \end{array}$$

Dem:  $E(X+Y) = \sum_z z P(X+Y=z)$

Marginalización

$$= \sum_z \sum_y z P(X+Y=z, Y=y)$$

$\underbrace{z = x+k}_{\text{conjunta}}$

$$= \sum_z \sum_y \sum_x \underbrace{(x+k)}_{z=x+k} P(X=x, Y=y) = \sum_x \sum_y (x+y) P(X=x, Y=y)$$

$$\begin{aligned}
&= \sum_x \sum_y x P(X=x, Y=y) + \sum_x \sum_y y P(X=x, Y=y) \\
&= \sum_x x \left( \sum_y P(X=x, Y=y) \right) + \sum_y y \left( \sum_x P(X=x, Y=y) \right) \\
&\stackrel{\text{Marg.}}{=} \sum_x x P(X=x) + \sum_y y P(Y=y) = E(X) + E(Y)
\end{aligned}$$

$$\cdot) E(aX) = \sum_k k P(aX=k) = \sum_x ax P(X=x) = a E(X).$$


---

Más general

$$\textcircled{2} E[h(X)] = \int \int \underbrace{h(x)}_{\text{circled}} f_X(x) dx$$

$$\left\{ \begin{array}{l} h: \mathbb{R} \rightarrow \mathbb{R} \\ \sum_x h(x) P(X=x) \end{array} \right.$$

Examples

$$h(X, Y) = X + Y$$

$$h(X) = aX$$

De hecho, con vectores aleatorios

$$E[h(X_1, \dots, X_n)] = \int \dots \int h(x_1, \dots, x_n) f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_1 \dots dx_n$$

$$\left\{ \begin{array}{l} h: \mathbb{R}^n \rightarrow \mathbb{R} \\ \sum_{x_1} \dots \sum_{x_n} h(x_1, \dots, x_n) P(X_1=x_1, \dots, X_n=x_n) \end{array} \right.$$

... entonces la esperanza conserva combinaciones lineales  $E(Z\alpha X) = Z\alpha E(X)$   
¿Qué pasa con la varianza?

$$(3) \cdot \text{Var}(aX) = a^2 \text{Var}(X)$$

Dem  $\text{Var}(aX) = E[(aX - E(aX))^2] = E[a^2(X - E(X))^2]$   
 $= a^2 E[(X - E(X))^2]$   
 $= a^2 \text{Var}(X)$

$\cdot \text{Var}(X+Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X,Y)$

Dem:

$$\text{Var}(X+Y) = E[(X+Y - E(X+Y))^2]$$

$$= E[(X - E(X)) + (Y - E(Y))]^2$$

$$= E[(X - E(X))^2 + (Y - E(Y))^2 + 2(X - E(X))(Y - E(Y))]$$

$$= \underbrace{E[(X - E(X))^2]}_{\text{Var}(X)} + \underbrace{E[(Y - E(Y))^2]}_{\text{Var}(Y)} + 2 \underbrace{E[(X - E(X))(Y - E(Y))]}_{\text{Cov}(X,Y)}$$

(7) Sea  $X, Y$  v.a  $\Sigma = \begin{pmatrix} \sigma_{xx} & \sigma_{xy} \\ \sigma_{xy} & \sigma_{yy} \end{pmatrix}$

$\sigma_{xx} = \text{Var}(X) = \text{Cov}(X, X)$   
 $\sigma_{xy} = \text{Cov}(X, Y)$   
 $\sigma_{yy} = \text{Var}(Y) = \text{Cov}(Y, Y)$

$\Sigma$  se llama matriz de covarianzas

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y)$$

$$= a^2 \sigma_{xx} + b^2 \sigma_{yy} + 2ab \sigma_{xy}$$

$$= [a, b] \begin{bmatrix} \sigma_{xx} & \sigma_{xy} \\ \sigma_{xy} & \sigma_{yy} \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix}$$

$$= w^T \Sigma w \quad \text{con } w = \begin{pmatrix} a \\ b \end{pmatrix}$$

De manera más general

Si  $X_1, \dots, X_n$  son v.a.s y  $\Sigma = [\text{Cov}(X_i, X_j)]_{i,j=1}^n$   
 y  $a = (a_1, \dots, a_n)$  vector de coeficientes, entonces

$$\text{Var}(\sum a_i X_i) = a^T \Sigma a$$

## Ejemplo aplicación

- Finanzas  $\mu$  sector de rendimientos esperados de activos  
 $\Sigma$  matriz de covarianzas

### Problema de Optimización de portafolios

$$\begin{array}{ll} \max & w^T \mu \leftarrow \text{rendimiento de un portafolio} \\ \text{p.a.} & w^T \Sigma w = c \leftarrow \text{sujeto a un nivel de riesgo constante} \end{array}$$

- Reducción de dimensionalidad [Ver en más detalle después]

Dadas  $X_1, \dots, X_n$  cuál será la combinación lineal que presente mayor información (en términos de varianza)

$$\begin{array}{ll} \max_{a \neq 0} & \text{Var}(\sum a_i X_i) \sim \max_a a^T \Sigma a \\ \text{s.a.} & \|a\| = 1 \end{array}$$

Solución es un eigenvector de  $\Sigma$ . (por lagrangianos)  $\downarrow$   
i.e.,  $\boxed{\Sigma a = \lambda a}$  y  $\text{Var}(\sum a_i X_i) = a^T (\sum a_i^2) = \lambda (a^T a) = \lambda$

Buscar el eigenvector de  
eigenvalor más grande

eigenvector  
a la máxima  
varianza

# Procesos Estocásticos <sup>= Aleatorio</sup>


Estocásticos es un sinónimo de aleatorio.

En vez de tener una sola variable aleatoria  $X$ , queremos estudiar el comportamiento de una *secuencia* de variables aleatorias  $(X_t)_{t \geq 0} = X_1, X_2, \dots$

Cada variable aleatoria representa un momento en el tiempo. Las variables no tienen que ser independientes.

# Ejemplos:

- El precio de una acción.
- La posición de una partícula de polen suspendida en el aire.
- El número de clientes que hay en una tienda
- El estado del clima





# Cadenas de Markov

Independencia

$$P(A|B) = P(A)$$

Independencia condicional a C

$$P(A|B, C) = P(A|C)$$

- El estado próximo depende sólo del estado actual.
- Más precisamente, las probabilidades de transición están determinadas por el estado actual.

$$P(X_{t+1} = x_{t+1} | X_0 = x_0, \dots, X_t = x_t) = P(X_{t+1} = x_{t+1} | X_t = x_t)$$

El futuro es independiente del pasado condicional al presente  
 $X_{t+1}$   $X_0, \dots, X_t$   $X_t$

- **Motivación inicial:** un modelo para estudiar el lenguaje.

Si cada  $x_t$  es una palabra

a) Predecir la próxima palabra de un texto

¿Es Markoviano?

b) ¿Si cada  $x_t$  son las últimas 5 palabras?



A. A. Markov (1866).

# Inspiración Física

✓ estado de un sistema dinámico

$$S_{t+1} = f(S_t)$$

Markov

componente determinista

componente aleatorio

$$S_{t+1} = f(S_t, E_t)$$

Nota: La propiedad de Markov es un supuesto aparentemente fuerte pero muchas cosas se pueden "modelar" en la práctica Markovianamente.

- .) Incluyendo información adicional relevante
- .) Haciendo trampa e incluyendo "lags".

- Para conocer las probabilidades del futuro solo necesitas conocer el presente!

*Matemáticamente...*

- Si  $S$  son todos los posibles “estados” de la cadena (los valores que pueden tomar las  $X_t$ ) **la propiedad de Markov dice:**



(homogénea)

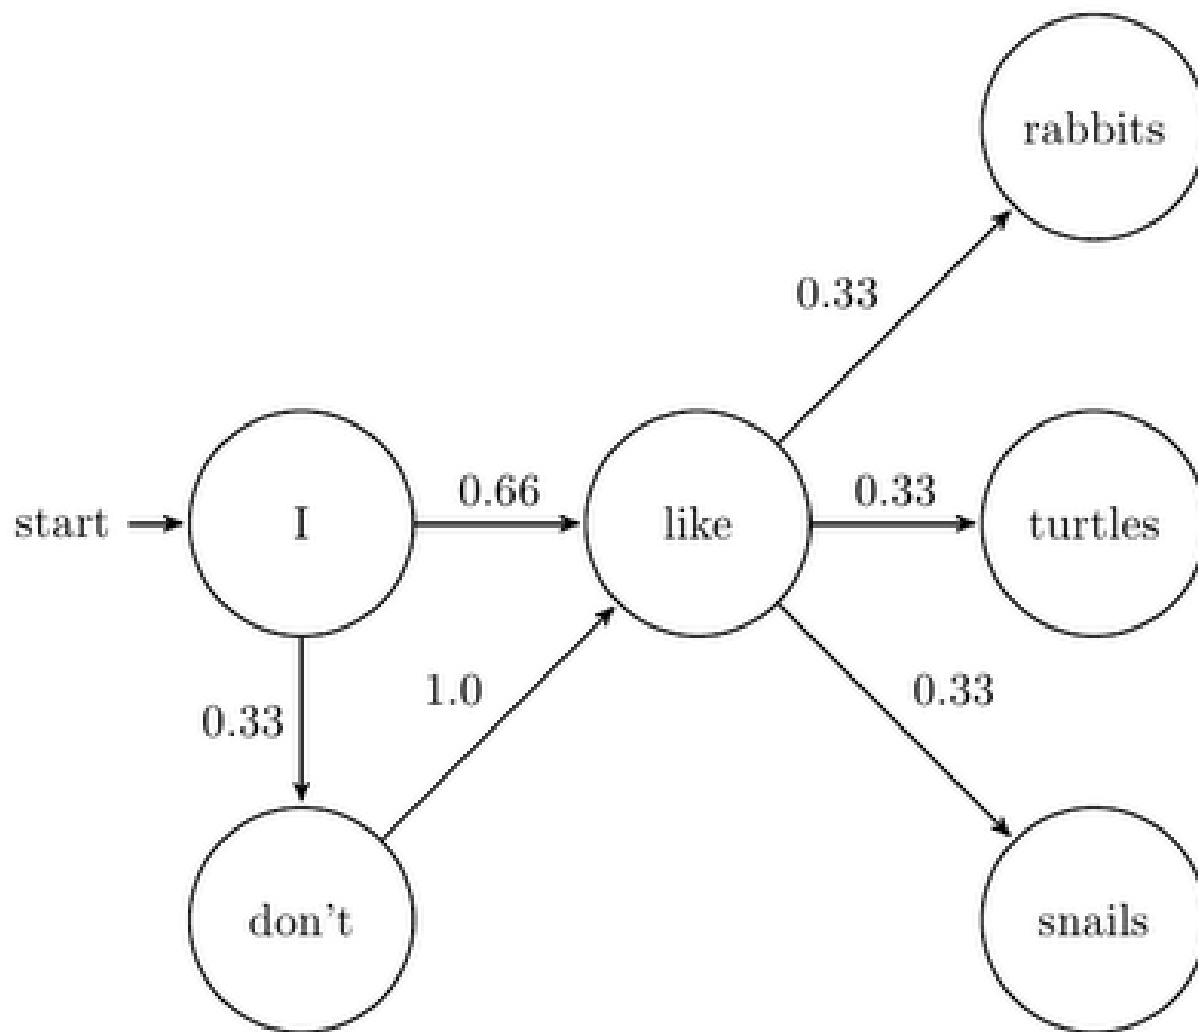
# Que es una cadena de Markov

- Es tres cosas:

1. Un conjunto de estados  $S$
2. Una distribución inicial para  $X_0$
3. Un “Kernel” de transición. Unas probabilidades de transición por cada estado actual.

$S$  finito.... El kernel puede representarse como matriz  
 $P = (P_{ij})$

$$P_{ij} = \mathbb{P}(X_{t+1}=j | X_t=i)$$



# Distribución de las variables $X_t$

- ¿Cómo son las distribuciones de  $X_t$  condicionando a la distribución inicial de  $X_0$ ?







# Aplicación de las cadenas de Markov

- Hay dos aplicaciones principales
  1. Aprender cómo es  $P$  para poder predecir
  2. Ya sabes como es  $P$  pero cómo se comportará un sistema en el largo plazo.

A continuación vamos a hablar del comportamiento largo plazo de las cadenas de Markov y vamos a dar uno de los ejemplos de aplicación más famosos... (Google PageRank).

# Distribución límite/estacionaria

